Rapport de projet – JobTech

Cartographie du marché de l'emploi Tech en Europe

Date de rendu : 04/07/2025

1. Introduction

Face à la pénurie de profils Tech en Europe, notre mission était de construire un socle technique permettant à la Commission européenne d'avoir une vision claire, à jour et accessible du marché de l'emploi Tech à travers l'Europe. Nous avons mis en place un Data Lake, un Data Warehouse, et une API REST permettant de valoriser ces données sous forme de services exploitables.

2. Objectifs du projet

- Collecter des données récentes multi-sources sur l'emploi Tech en Europe.

- Nettoyer, normaliser, et centraliser ces données.

- Concevoir un Data Warehouse orienté emploi & compétences.

- Fournir une API REST sécurisée pour exposer les données de manière exploitable.

- Documenter et publier l'ensemble du travail sur GitHub.

3. Architecture Générale

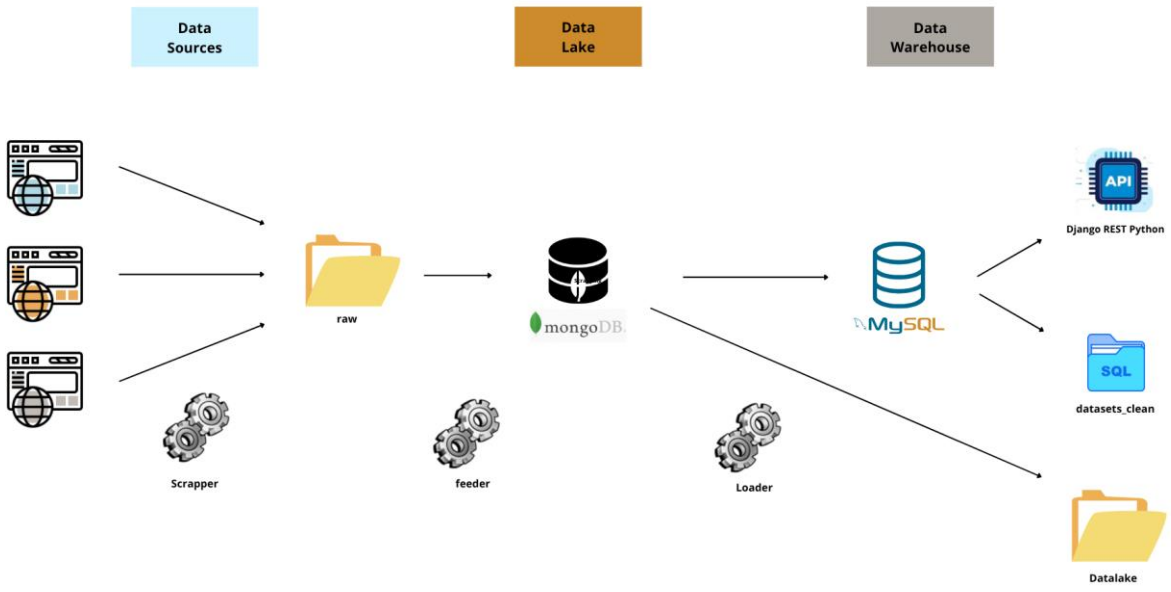

Stack Technique :

- Langage principal : Python 3.11

- Scraping & APIs : requests, BeautifulSoup, Selenium

- Stockage brut : fichiers CSV / JSON dans data/raw/

- Base de données : MongoDB (Data Lake) ,MySQL (Data Warehouse)

- ORM / API : Django 5 + Django REST Framework

- Documentation : README, Postman, ce rapport PDF

- Autres dépendances : pandas, SQLAlchemy, pytrends, dotenv, pymongo, django (pour l'API REST)

4. Collecte des données

Sources exploitées :

- Adzuna API : Intitulé, salaire, localisation, skill

- GitHub API : Repos tendance, stars, langage

- Stack Overflow Survey : Stack préférée, techno, salaires

5. Nettoyage et Normalisation

Nettoyages structurels

- Supprime la clé `"_id"` issue de MongoDB.
- Récupère puis supprime la clé `"_collection"` pour l'ajouter à la fin du traitement.

Normalisation via Pandas

- Convertit le document en un DataFrame à une seule ligne.
- Met tous les noms de colonnes en minuscules.
- Convertit toutes les valeurs textuelles (`str`) en minuscules.
- Mets en anglais le nom des colonnes dans le datawarehouse

Nettoyage du contenu

- Remplace toutes les chaînes `"unknown"` par `"non-renseigné"`.
- Supprime les colonnes où toutes les valeurs sont nulles (NaN).

Nettoyage des dates

- Pour les champs `"created_at"` et `"updated_at"` :
    - Tente de les parser au format ISO avec `isoparse`.
    - En cas d'échec, remplace la valeur par None.

Finalisation

- Réintègre le champ `"_collection"` dans le document nettoyé.
- Retourne un dictionnaire propre et prêt à être inséré en base.

6. Stockage – Data Lake & Data Warehouse

Data Lake :

Les fichiers bruts sont stockés dans data/raw/.

Puis sont envoyez dans MongoDB tel quel

Data Warehouse :

Les données sont nettoyées et retravaillées puis sont envoyé dans Mysql

7. API REST

Déployée avec Django REST Framework.

Endpoints clés : Différents GET pour récupérer les datasets des différentes conllections (top_tech, adzuna, database, platform, web_framework)

Authentification : Token dans les headers

Création d'une application fonctionnelle avec création de compte obligatoire pour récupérer une clé API.

Postman : export complet dans api/postmanecollection.txt

9. Déploiement et documentation

- Repo GitHub : https://github.com/linjacques/jobtech

- README.md : Instructions d'installation

- Documentation API : via Postman

10. Perspectives d'amélioration

- Dashboard Power BI

- Passage à une base en cloud (ex : BigQuery, Snowflake)

11. Conclusion

Ce projet a permis de transformer des données hétérogènes en un système d'information unifié, sécurisé et consultable via API. L'architecture est prête pour être étendue à l'échelle européenne.